

UNIVERSIDAD NACIONAL DEL ALTIPLANO - PUNO

**FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA,
ELECTRÓNICA Y SISTEMAS**

**ESCUELA PROFESIONAL DE INGENIERÍA DE
SISTEMAS**



**DETECCIÓN DE ATAQUES MINORITARIOS EN REDES
IoT MEDIANTE UN MODELO HÍBRIDO BASADO EN
STACKING, XGBOOST Y LIGHTGBM, PUNO 2026**

BORRADER DE TESIS

PRESENTADA POR:

CARMEN NIEVES APAZA CONDORI

PARA OPTAR EL TÍTULO PROFESIONAL DE:

INGENIERO DE SISTEMAS

PUNO - PERÚ

2026

UNIVERSIDAD NACIONAL DEL ALTIPLANO

PUNO

FACULTAD DE INGENIERÍA MECÁNICA ELÉCTRICA, ELECTRÓNICA Y SISTEMAS

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

TESIS

DETECCIÓN DE ATAQUES MINORITARIOS EN REDES IOT MEDIANTE UN MODELO HÍBRIDO BASADO EN STACKING, XGBOOST Y LIGHTGBM

PUNO 2026

Presentado por:

Bach. Carmen Nieves Apaza Condori

Para optar el título profesional de:

INGENIERO DE SISTEMAS

APROBADA POR:

PRESIDENTE: Pablo Cesar Tapia Catacora
Dr. Presidente de Jurado

PRIMER MIEMBRO: Carlos Boris Sosa Maydana
Dr. Primer miembro de Jurado

SEGUNDO MIEMBRO: Ubaldo Allca Mamani
Dr. Segundo miembro de Jurado

DIRECTOR / ASESOR: Hugo Yosef Gomez Quispe
Dr. Asesor de Tesis

Área: Inteligencia Artificial

Tema: Detección de ataques minoritarios en redes IoT mediante modelo híbrido basado en Stacking, XGBoost y LightGBM

ÍNDICE GENERAL

Índice General	4
Índice de Tablas	5
Índice de Figuras	6
Índice de Acrónimos	7
1. INTRODUCCIÓN	1
1.1. CONTEXTUALIZACIÓN	1
1.2. REALIDAD PROBLEMÁTICA	2
1.3. FORMULACIÓN DEL PROBLEMA	3
1.3.1. Problema General	3
1.3.2. Problemas Específicos	3
1.4. JUSTIFICACIÓN	3
1.5. OBJETIVOS	4
1.5.1. OBJETIVO GENERAL	4
1.5.2. OBJETIVOS ESPECÍFICOS	5
1.6. HIPÓTESIS DE LA INVESTIGACIÓN	5
1.6.1. Hipótesis general	5
1.6.2. Hipótesis específicas	5
1.7. VARIABLES	6
1.7.1. Variable Independiente (VI)	6
1.7.2. Variable Dependiente (VD)	6
1.8. OPERACIONALIZACIÓN DE VARIABLES	6
2. REVISIÓN DE LITERATURA	7
2.1. Antecedentes	7

2.1.1.	Antecedentes internacionales	7
2.1.2.	Antecedentes nacionales	13
2.1.3.	Antecedentes locales	15
2.2.	Bases Teóricas	15
2.2.1.	Internet de las Cosas (IoT) y Ciberseguridad	15
2.2.2.	Algoritmos de Gradiente Incrementado (Boosting)	15
2.2.3.	XGBoost (Extreme Gradient Boosting)	15
2.2.4.	LightGBM (Light Gradient Boosting Machine)	15
2.2.5.	Ensamble por Stacking (Apilamiento)	16
2.2.6.	Técnicas de Tratamiento de Desbalance de Clases	16
2.2.7.	Borderline-SMOTE	16
2.2.8.	Métricas de Evaluación de Clasificación	16
2.3.	Definición de Términos Básicos	17
3.	MATERIALES Y MÉTODOS	18
3.1.	Materiales	18
3.1.1.	Equipos	18
3.1.2.	Software	19
3.2.	Metodología	19
3.2.1.	Tipo de investigación	19
3.2.2.	Diseño de investigación	19
3.2.3.	Población y muestra	20
3.2.4.	Técnicas e instrumentos de recolección de datos	21
3.2.5.	Procedimiento de la investigación	21
3.2.6.	Análisis de datos	22
4.	RESULTADOS Y DISCUSIÓN	23
4.1.	Resultados	23
4.2.	Discusión	23
5.	CONCLUSIONES	24
5.1.	Conclusión 1	24
5.2.	Conclusión 2	24
5.3.	Conclusión 3	24

6. RECOMENDACIONES	25
6.1. Recomendación 1	25
6.2. Recomendación 2	25
7. ANEXOS	26
7.1. Anexo A: Título del anexo A	26
7.2. Anexo B: Título del anexo B	26

ÍNDICE DE CUADROS

1.1. Matriz de Operacionalización de Variables	6
3.1. Especificaciones técnicas del hardware utilizado en la experimentación	18
3.2. Herramientas de software y librerías empleadas	19

ÍNDICE DE FIGURAS

ÍNDICE DE ACRÓNIMOS

API	Application Programming Interface (Interfaz de Programación de Aplicaciones)
CIC-IoT	Canadian Institute for Cybersecurity Internet of Things (Instituto Canadiense de Ciberseguridad para IoT)
DoS	Denial of Service (Denegación de Servicio)
IDPS	Intrusion Detection and Prevention System (Sistema de Detección y Prevención de Intrusiones)
IoT	Internet of Things (Internet de las Cosas)
ML	Machine Learning (Aprendizaje Automático)
NIDS	Network Intrusion Detection System (Sistema de Detección de Intrusiones de Red)
RF	Random Forest (Bosque Aleatorio)
SVM	Support Vector Machine (Máquina de Vectores de Soporte)
XGBoost	eXtreme Gradient Boosting (Gradient Boosting Extremo)
LightGBM	Light Gradient Boosting Machine (Máquina de Gradient Boosting Ligero)
Stacking	Stacking Ensemble (Aprendizaje por Apilamiento)
IoTMT	IoT Malware Traffic (Tráfico de Malware IoT)
IDS	Intrusion Detection System (Sistema de Detección de Intrusiones)
MLP	Multi-Layer Perceptron (Perceptrón Multicapa)
CNN	Convolutional Neural Network (Red Neuronal Convolucional)
LSTM	Long Short-Term Memory (Memoria de Corto y Largo Plazo)

CAPÍTULO I

INTRODUCCIÓN

1.1 CONTEXTUALIZACIÓN

El despliegue masivo de dispositivos interconectados bajo el paradigma de la Internet de las Cosas (IoT) ha transformado radicalmente la infraestructura digital global, facilitando la automatización en sectores críticos como la industria, la salud y las ciudades inteligentes. Sin embargo, esta expansión ha incrementado exponencialmente la superficie de exposición ante amenazas cibernéticas cada vez más sofisticadas. Según Sama et al., (2025), la naturaleza heterogénea de estas redes y las limitaciones intrínsecas de recursos en los nodos finales dificultan la implementación de mecanismos de seguridad convencionales, lo que genera brechas que son aprovechadas por atacantes para comprometer la integridad y disponibilidad de los datos.

A pesar del desarrollo continuo de sistemas de detección de intrusiones (IDS) basados en aprendizaje automático, la identificación de anomalías en entornos de red reales enfrenta el desafío crítico del desbalance de clases. La mayoría de los modelos de clasificación actuales tienden a sesgarse hacia el tráfico mayoritario (tráfico benigno), lo que resulta en una incapacidad para reconocer patrones de ataques minoritarios que, aunque poseen una baja frecuencia de aparición, representan las amenazas más disruptivas para la infraestructura (Ahmed et al., 2024). Esta subrepresentación de los ataques en los conjuntos de datos de entrenamiento provoca que las intrusiones críticas pasen desapercibidas bajo el flujo de red normal.

En este escenario, resulta imperativo el desarrollo de arquitecturas híbridas que no solo mejoren la precisión global, sino que optimicen la detección en los bordes de decisión donde residen los ataques minoritarios. El uso de técnicas de selección de características basadas en la entropía para reducir la incertidumbre, combinado con el sobremuestreo sintético mediante Borderline-SMOTE, permite reequilibrar la importancia de las clases dentro del modelo. Al integrar algoritmos potentes como XGBoost y LightGBM bajo una estructura de Stacking, se busca alcanzar

un nivel de resiliencia superior en la ciberseguridad de redes IoT, permitiendo una respuesta más ágil y precisa frente a las amenazas emergentes (Diwan et al., 2021; Lin et al., 2021).

1.2 REALIDAD PROBLEMÁTICA

En la actualidad, la seguridad de las redes IoT se enfrenta a un desafío técnico crítico: la ineficacia de los sistemas de detección de intrusiones convencionales frente a ataques de baja frecuencia o minoritarios. A medida que los ciberataques evolucionan en complejidad, los modelos estándar de aprendizaje automático demuestran una alta precisión para detectar tráfico masivos, como los ataques de denegación de servicio (DDoS); sin embargo, exhiben un rendimiento deficiente al identificar intrusiones más sutiles y específicas que ocurren con menor periodicidad. Según Ahmed et al., (2024), el conjunto de datos moderno CIIoT2023 ejemplifica esta problemática al presentar una distribución de clases extremadamente desbalanceada, donde determinadas categorías de ataque representan menos del 1

Esta disparidad en la representación de los datos genera un sesgo algorítmico donde el modelo prioriza la clase mayoritaria (tráfico benigno o ataques masivos), comprometiendo la seguridad ante vulnerabilidades que requieren una detección temprana y precisa. Sama et al., (2025) señalan que los métodos de ensamble estándar no logran capturar adecuadamente las fronteras de decisión de las clases minoritarias si no se integran estrategias de preprocesamiento robustas y una selección de características orientada a reducir el ruido. En el contexto de las infraestructuras de red en regiones como Puno, la creciente adopción de soluciones IoT en la gestión de servicios básicos y sistemas industriales carece de mecanismos de monitoreo adaptativos que consideren la incertidumbre intrínseca de los datos de red. La falta de un análisis profundo sobre la entropía de las características y la ausencia de técnicas de balanceo sintético en la frontera (como Borderline-SMOTE) resulta en una alta tasa de falsos negativos para ataques que podrían comprometer la integridad de sistemas críticos.

Por consiguiente, el problema central radica en la inexistencia de una arquitectura de detección que logre un equilibrio óptimo entre la precisión general y la sensibilidad (recall) hacia las anomalías de baja frecuencia. Los modelos individuales, aunque eficientes en tiempo, no poseen la capacidad de generalización necesaria para discernir patrones complejos en entornos IoT altamente dinámicos y ruidosos. Existe una brecha tecnológica que demanda la implementación de modelos híbridos basados en Stacking que, mediante la combinación estratégica de XGBoost y LightGBM, logren mitigar las debilidades de los algoritmos base y proporcionen una capa

de seguridad resiliente capaz de identificar con éxito los ataques minoritarios que actualmente pasan desapercibidos.

1.3 FORMULACIÓN DEL PROBLEMA

1.3.1 Problema General

¿En qué medida el Modelo híbrido basado en Stacking, XGBoost y LightGBM mejora la eficacia en la detección de ataques minoritarios en redes IoT?

1.3.2 Problemas Específicos

- **PE1:** ¿En qué grado la técnica de rebalanceo Borderline-SMOTE incrementa la proporción de balance de la clase minoritaria en el dataset CICIoT2023 respecto al balance original?
- **PE2:** ¿Cuál es la capacidad de detección del Modelo híbrido basado en Stacking, XGBoost y LightGBM en la identificación de ataques minoritarios evaluada mediante las métricas de evaluación Recall, F1-Score y Accuracy?
- **PE3:** ¿Cuál es la eficiencia computacional del Modelo híbrido basado en Stacking, XGBoost y LightGBM propuesto en términos de tiempos de entrenamiento y latencia de inferencia frente a los modelos base Random Forest y XGBoost?

1.4 JUSTIFICACIÓN

La seguridad en las redes del Internet de las Cosas (IoT) atraviesa un momento crítico, ya que el panorama de amenazas evoluciona con tal rapidez que las defensas tradicionales resultan insuficientes, además se encuentran limitadas por la escasez de recursos y la naturaleza dinámica de estas redes. Por lo tanto, la problemática se agrava debido al desbalance de clases en los datos industriales, puesto que cuando ciertos ataques están subrepresentados, los modelos de aprendizaje automático convencionales fallan en su detección, generando así brechas de seguridad.

Surge entonces la necesidad de superar estas barreras mediante métodos de ensamble avanzados, ya que estudios recientes, como el de Sama et al., (2025), demuestran que la implementación de arquitecturas de Stacking en modelos híbridos (XGBoost y LightGBM) no solo supera a los modelos individuales en métricas de Accuracy y Recall, sino que también es fundamental

para reducir la incertidumbre en la detección. Sin embargo la combinación simple no basta, tal como señalan Ahmed et al., (2024), quienes confirman que el Stacking debe integrarse con una selección de características robusta para garantizar la estabilidad del sistema, y en consecuencia esta propuesta evoluciona hacia una arquitectura basada en Entropía para medir la incertidumbre de cada predicción, siendo este un enfoque validado por Popoola et al., (2025), quienes además evidencian que el uso de métricas de entropía permite discriminar con mayor precisión ataques complejos que los métodos tradicionales pasan por alto.

De esa misma forma, la integración de la técnica Borderline-SMOTE para equilibrar los datos y definir mejor las fronteras de decisión se justifica en investigaciones recientes como las de Nigar y Mustafa, (2025), quienes demostraron en sus hallazgos y corroboran que el tratamiento previo con técnicas de resampling híbrido es un componente esencial para mitigar el sesgo hacia las clases mayoritarias y optimizar el rendimiento de clasificadores potentes como XGBoost. Además, desde un enfoque económico y operativo, la optimización del modelo resulta vital para escenarios de IoT, ya que la selección de características y la reducción de dimensionalidad propuestas permitirán disminuir el consumo de recursos y los tiempos de latencia, garantizando así un análisis eficaz del tráfico en tiempo real y asegurando la viabilidad técnica del sistema.

Si bien se utiliza el dataset CICIoT2023 de origen canadiense por ser un estándar de referencia global validado para la investigación científica, los patrones de tráfico y vectores de ataque analizados (protocolos TCP/UDP, arquitecturas MQTT) son agnósticos a la ubicación geográfica. Esto permite que el modelo propuesto sea extrapolable y aplicable a la realidad tecnológica peruana incipiente, sirviendo como una base proactiva de seguridad.

Por último, cabe mencionar también la importancia social y práctica de este proyecto de investigación, ya que este radicará en la protección de dos aspectos fundamentales: la integridad y la privacidad de los dispositivos IoT. Los cuales presentan vulnerabilidades ante intrusiones que comprometen los servicios esenciales de los entornos IoT. Esta investigación propone el desarrollo y validación de un modelo robusto sobre el dataset CICIoT2023, adoptando una solución proactiva y adaptable que supera las limitaciones de los métodos existentes.

1.5 OBJETIVOS

1.5.1 OBJETIVO GENERAL

Determinar la eficacia del Modelo Híbrido basado en Stacking, XGBoost y LightGBM en la mejora de la detección de ataques minoritarios en redes IoT.

1.5.2 OBJETIVOS ESPECÍFICOS

- **OE1:** Evaluar la mejora en la proporción de balance de la clase minoritaria mediante la aplicación de la técnica de rebalanceo Borderline-SMOTE en el dataset CICIoT2023.
- **OE2:** Determinar la capacidad de detección del Modelo Híbrido basado en Stacking, XGBoost y LightGBM en la identificación de ataques minoritarios utilizando las métricas de evaluación Recall, F1-Score y Accuracy.
- **OE3:** Comparar la eficiencia computacional del modelo híbrido propuesto midiendo los tiempos de entrenamiento y latencia de inferencia frente a los modelos base Random Forest y XGBoost.

1.6 HIPÓTESIS DE LA INVESTIGACIÓN

1.6.1 Hipótesis general

El Modelo Híbrido basado en Stacking, XGBoost y LightGBM mejora significativamente la eficacia (Recall y F1-Score) en la detección de ataques minoritarios en redes IoT, superando el rendimiento de los modelos base en el dataset CICIoT2023.

1.6.2 Hipótesis específicas

- **HE1:** La técnica de rebalanceo Borderline-SMOTE incrementa significativamente la proporción de balance de la clase minoritaria en el dataset CICIoT2023, reduciendo el índice de desbalance y mejorando la distribución de datos en la frontera de decisión.
- **HE2:** El Modelo Híbrido XGB-LGBM-Stacking con análisis de incertidumbre presenta una alta capacidad de detección de ataques minoritarios, evidenciando indicadores superiores en las métricas de Recall, F1-Score y Accuracy al ser validados estadísticamente mediante la prueba de rangos con signo de Wilcoxon.
- **HE3:** El modelo híbrido propuesto optimiza la eficiencia computacional, logrando tiempos de entrenamiento y una latencia de inferencia competitivos en comparación con los modelos base Random Forest y XGBoost, garantizando su viabilidad operativa.

1.7 VARIABLES

1.7.1 Variable Independiente (VI)

Modelo híbrido basado en Stacking, XGBoost y LightGBM, optimizado con la técnica de rebalanceo de datos Borderline-SMOTE.

1.7.2 Variable Dependiente (VD)

Detección de ataques minoritarios en redes IoT, evaluada a través de la eficacia predictiva y el desempeño computacional.

1.8 OPERACIONALIZACIÓN DE VARIABLES

Tabla 1.1: Matriz de Operacionalización de Variables

Variable	Definición Conceptual	Definición Operacional	Dimensiones	Indicadores	Escala de Medición
Variable Independiente:					
Modelo híbrido basado en Stacking (XGBoost, LightGBM) con análisis de incertidumbre y Borderline-SMOTE	Sistema algorítmico compuesto por múltiples modelos de aprendizaje (ensamble) que integra la cuantificación de incertidumbre y sobremuestreo sintético para aprender patrones en datos desbalanceados sin programación explícita	Configuración computacional en Python que utiliza Entropía de Shannon para características y Borderline-SMOTE para rebalanceo, entrenando un metamodelo Stacking	1. Arquitectura de Ensamble. 2. Preprocesamiento de Datos	1. Algoritmos base utilizados (XGBoost, LightGBM). 2. Nivel de Entropía de Shannon. 3. Ratio de balanceo de clases	Nominal (Tipo de algoritmo base). Razón (para nivel de entropía y ratio de balanceo)
Variable Dependiente:					
Detección de ataques minoritarios en redes IoT	Capacidad de un modelo de aprendizaje automático para identificar y clasificar anomalías de baja frecuencia en volúmenes masivos de tráfico de red	Evaluación del rendimiento del modelo al clasificar flujos del dataset CICIoT2023, midiendo métricas de precisión y tiempos de procesamiento	1. Eficacia Predictiva. 2. Desempeño Computacional	1. Precisión (Accuracy). 2. Sensibilidad (Recall). 3. F1-Score. 4. Latencia de inferencia (ms)	Razón (para precisión, recall, F1-Score y latencia de inferencia)

CAPÍTULO II

REVISIÓN DE LITERATURA

2.1 Antecedentes

2.1.1 Antecedentes internacionales

1. Abou Elasaad et al. (2025), en su artículo AegisGuard: A Multi-Stage Hybrid Intrusion Detection System with Optimized Feature Selection for Industrial IoT Security, propusieron un estudio experimental orientado a fortalecer ecosistemas IIoT mediante arquitecturas de análisis secuencial. La metodología implementó AegisGuard, un modelo modular de múltiples etapas que filtra flujos maliciosos aplicando selección dinámica de características. Los resultados evidenciaron empíricamente que este enfoque estratificado supera estadísticamente a los sistemas de etapa única en la neutralización asertiva de ciberataques estructuralmente complejos. Este trabajo respalda concluyentemente el paradigma de construir arquitecturas híbridas y multicapa; sin embargo, no atiende primariamente el sesgo algorítmico generado por clases minoritarias subrepresentadas en la capa de entrada, variable crítica que esta tesis subsanará empleando el algoritmo Borderline-SMOTE.
2. Adewole et al. (2025), en Intrusion Detection Framework for Internet of Things with Rule Induction for Model Explanation, ejecutaron un diseño experimental para integrar capacidades de explicabilidad en sistemas de ciberseguridad IoT. Metodológicamente, utilizaron los conjuntos de datos CIC-IDS2017 y CICIOT2023 para evaluar el rendimiento de algoritmos de Gradient Boosting, incluyendo XGBoost, LightGBM y CatBoost. Los resultados demostraron la superioridad técnica de XGBoost, el cual alcanzó un Accuracy de 99.91
3. Ahmed et al. (2024), en An optimized ensemble model with advanced feature selection for network intrusion detection, realizaron un estudio de nivel explicativo con el objetivo

de optimizar la identificación de amenazas mediante la hibridación de algoritmos predictivos. La metodología consistió en integrar los modelos XGBoost y LightGBM bajo una arquitectura de ensamble tipo Stacking, evaluando el impacto de la remoción de atributos irrelevantes en la estabilidad sistémica. Los resultados confirmaron que la mitigación del ruido de entrada acelera significativamente el entrenamiento e incrementa la precisión global del clasificador. La relevancia de esta investigación radica en validar la efectividad estructural del modelo Stacking seleccionado; sin embargo, carece de un enfoque orientado específicamente a métricas de ataques minoritarios, dimensión que será el núcleo de evaluación del modelo propuesto en esta tesis.

4. Al-Emari et al. (2024), en su artículo *Employing Mutual Information Feature Selection and LightGBM for Intrusion Detection in IoT*, desarrollaron una investigación aplicada cuyo objetivo fue optimizar los mecanismos de protección de redes mediante la selección heurística de características. Metodológicamente, emplearon el algoritmo LightGBM evaluado sobre el conjunto de datos IoTID20, integrando el análisis de Información Mutua y optimización por enjambre de partículas. Los resultados revelaron que esta configuración supera a las técnicas convencionales en las métricas de exactitud, sensibilidad y F1-Score, reduciendo simultáneamente la tasa de falsos positivos. Este estudio demuestra fehacientemente la eficacia del clasificador LightGBM para entornos IoT; sin embargo, al utilizar un dataset genérico y optimizaciones de alto costo, deja un vacío técnico que la presente tesis cubrirá mediante el dataset CICIOT2023.
5. Almotairi et al. (2024), en *Enhancing intrusion detection in IoT networks using machine learning-based feature selection and ensemble models*, desarrollaron una investigación aplicada sobre la gestión algorítmica ante la alta heterogeneidad del tráfico en sistemas IoT. Su protocolo metodológico consistió en acoplar modelos de ensamble clásicos, como Random Forest y Gradient Boosting, con rutinas selectivas de atributos. Los hallazgos revelaron que una discriminación óptima de variables permite a las arquitecturas mantener tasas de exactitud excepcionales garantizando baja demanda de hardware de procesamiento. Este trabajo consolida la viabilidad de utilizar algoritmos basados en árboles de decisión en ecosistemas restrictivos; no obstante, carece de evaluación sobre conjuntos de ultra-alta dimensionalidad modernos, limitación que se superará al integrar el modelo con los 46 millones de flujos del CICIOT2023.

6. Alrayes et al. (2024), en *Intrusion Detection in IoT Systems Using Denoising Autoencoder*, desarrollaron una investigación aplicada enfocada en la seguridad para ecosistemas IoT sujetos a alta variabilidad y recursos limitados. Utilizaron Autoencoders de Eliminación de Ruido (DAE) basados en aprendizaje no supervisado para la extracción de características, validando el sistema con los conjuntos de datos CICIDS2017 y NSL-KDD. Los resultados exhibieron precisiones sobresalientes del 99.991
7. Berguiga et al. (2025), en *HIDS-IoMT: A Deep Learning-Based Intelligent Intrusion Detection System for the Internet of Medical Things*, plantearon un estudio experimental orientado a proteger redes de dispositivos médicos operando sobre arquitecturas computacionales de niebla. Metodológicamente combinaron redes convolucionales (CNN) y recurrentes (LSTM) para clasificar anomalías, ejecutando evaluaciones sobre los conjuntos de datos IoTID20 y Edge-IIoTset. Los hallazgos mostraron métricas críticas de Accuracy (99.92
8. Diwan et al. (2022), en su investigación *Feature Entropy Estimation (FEE) for Malicious IoT Traffic and Detection Using Machine Learning*, condujeron un estudio cuantitativo orientado a mejorar la identificación de actividades anómalas en volúmenes masivos de tráfico de red. La metodología propuesta consistió en utilizar la estimación de entropía para la ingeniería de características, evaluando algoritmos como XGBoost y Random Forest sobre el conjunto de datos Bot-IoT. Los hallazgos confirmaron que el uso de la entropía para discriminar atributos permite a los modelos alcanzar una precisión superior al 97
9. Ferrag et al. (2022), en su artículo *Edge-IIoTset: A New Comprehensive Realistic Cyber Security Dataset of IoT and IIoT Applications for Centralized and Federated Learning*, ejecutaron un diseño experimental con el objetivo de proponer y validar un nuevo conjunto de datos representativo de amenazas modernas. Metodológicamente, generaron perfiles de tráfico desde múltiples dispositivos físicos, extrayendo características correlacionadas para evaluar el rendimiento de algoritmos tradicionales y enfoques profundos. Los resultados evidenciaron que los modelos predictivos estándar presentan severas limitaciones de exactitud cuando se enfrentan a escenarios realistas de intrusión. La relevancia de este estudio estriba en demostrar la insuficiencia de los clasificadores individuales ante la complejidad del tráfico, justificando la necesidad de implementar metamodelos robustos.

10. Gutierrez et al. (2023), en Enhancing Intrusion Detection in IoT Communications Through ML Model Generalization With a New Dataset (IDSAI), ejecutaron una investigación aplicada destinada a cuantificar la capacidad de generalización en modelos de aprendizaje supervisado. La metodología introdujo el dataset normado y balanceado IDSAI para entrenar Random Forest, Gradient Boosting y XGBoost, validándolos posteriormente sobre el dataset externo Bot-IoT. Los hallazgos confirmaron a XGBoost como el modelo de mayor eficacia interna (94.97
11. Kouassi et al. (2025a), en Optimized Intrusion Detection in the IoT Through Statistical Selection and Classification with CatBoost and SNN, condujeron un estudio cuantitativo orientado a mejorar la detección de anomalías abordando directamente el problema del desbalance de clases. En su marco metodológico, aplicaron técnicas de remuestreo como SMOTE y RUS de forma conjunta con regresión LASSO, validando la arquitectura CatBoost en el dataset IoTID20. Los resultados indican que la configuración híbrida maximiza el rendimiento, logrando una precisión de 82.43
12. Kouassi et al. (2025b), en Top-K Feature Selection for IoT Intrusion Detection: Contributions of XGBoost, LightGBM, and Random Forest, desarrollaron una investigación aplicada orientada a reducir la carga computacional algorítmica en entornos IoT. Emplearon el dataset CICIoMT2024 aplicando una selección estadística Top-K sobre clasificadores supervisados, restringiendo las variables a las 10 y 15 más relevantes. Los hallazgos demostraron que el algoritmo Random Forest con Top-10 alcanzó un Accuracy de 91.7
13. Lin et al. (2021), en el documento Ensemble Learning for Threat Classification in Network Intrusion Detection on a Security Monitoring System for Renewable Energy, desarrollaron una investigación aplicada para categorizar amenazas informáticas mediante esquemas de aprendizaje por ensamble. En su metodología, contrastaron el rendimiento de algoritmos basados en bosques aleatorios frente a modelos de Gradient Boosting como XGBoost, procesando registros de tráfico de red para identificar anomalías. Los resultados comprobaron que los enfoques de ensamble garantizan una alta precisión y sensibilidad en la detección. Este antecedente consolida la viabilidad técnica de integrar algoritmos como XGBoost para tareas de clasificación crítica; sin embargo, presenta una oportunidad técnica para extender y optimizar esta arquitectura hacia ecosistemas IoT con la técnica SMOTE.

14. Musthafa et al. (2024), en *Optimizing IoT Intrusion Detection Using Balanced Class Distribution, Feature Selection, and Ensemble Machine Learning Techniques*, realizaron un estudio cuantitativo orientado a optimizar la fiabilidad de los sistemas de detección. La metodología consistió en implementar arquitecturas Stacking con LSTM, aplicando un balanceo de clases y selección de características sobre los conjuntos UNSW-NB15 y NSL-KDD. Los hallazgos indican que la configuración Stacking con filtrado estadístico alcanza una precisión de hasta 99.77
15. Nigar y Mustafa (2025), en *Enhanced Intrusion Detection via Hybrid Data Resampling and Feature Optimization*, elaboraron un diseño experimental combinando técnicas de optimización de atributos y sobremuestreo para estabilizar algoritmos predictivos. La metodología integró el algoritmo SMOTE para mitigar el desbalance previo al entrenamiento de ensambles modernos, particularmente XGBoost y LightGBM. Los resultados arrojaron que este preprocesamiento conjunto reduce significativamente el ratio de falsos positivos y proporciona alta estabilidad analítica frente a vectores de ataque de día cero. Este estudio proporciona un respaldo metodológico robusto; sin embargo, no contempla metadatos de incertidumbre lógica (entropía) para asistir la predicción, confirmando el vacío técnico que resolverá la presente propuesta de Stacking.
16. Popoola et al. (2025), en *Multi-Stage Deep Learning for Intrusion Detection in Industrial Internet of Things*, propusieron una investigación aplicada para resolver la identificación de ataques en entornos IIoT altamente desbalanceados. Su metodología incorporó un enfoque de aprendizaje profundo multi-etapa que utiliza la métrica de entropía para discriminar la incertidumbre predictiva, evaluado en los datasets X-IIOTID y WUSTL-IIoT. Los resultados evidenciaron métricas de precisión superiores al 99
17. Sama et al. (2025), en su artículo *Cutting-Edge Intrusion Detection in IoT Networks: A Focus on Ensemble Models*, ejecutaron un estudio cuantitativo cuyo objetivo fue optimizar la detección de intrusiones mediante modelos de ensamble. Metodológicamente, emplearon datasets masivos de tráfico de red para evaluar la arquitectura híbrida Stacking, combinando XGBoost y LightGBM junto con métricas de incertidumbre (entropía). Los resultados evidenciaron que este modelo supera estadísticamente a los clasificadores individuales en las métricas de Accuracy y Recall, minimizando simultáneamente las falsas alarmas. Este antecedente sustenta empíricamente la superioridad del ensamble propues-

to; sin embargo, no aborda el desbalance extremo de datos, justificando la inclusión de la técnica Borderline-SMOTE en la presente investigación.

18. Sayegh et al. (2024), en Enhanced Intrusion Detection with LSTM-Based Model, Feature Selection, and SMOTE for Imbalanced Data, realizaron un estudio cuantitativo orientado a elevar las tasas de detección mitigando el sesgo algorítmico. La metodología integró el remuestreo SMOTE con selección de características RFE, evaluando el desempeño en datasets heterogéneos (CIC-IDS2017, NSL-KDD, UNSW-NB15). Los resultados confirmaron que la aplicación de SMOTE incrementa drásticamente la capacidad de detección, alcanzando precisiones pico de 99.34
19. Sepúlveda-Fontaine y Amigó (2024), en el estudio teórico Applications of Entropy in Data Analysis and Machine Learning: A Review, condujeron una investigación documental con el objetivo de sistematizar el uso de medidas entrópicas en la optimización algorítmica. Metodológicamente, revisaron la aplicación de la entropía de Shannon como un funcional axiomático para caracterizar distribuciones de masa de probabilidad en el contexto de la minería de datos. Sus conclusiones determinaron que la entropía resulta excepcionalmente adecuada para evaluar la importancia de las características y medir el error en modelos predictivos. Este antecedente provee el sustento teórico y matemático necesario para justificar la integración de la Entropía de Shannon como parámetro de evaluación en el metamodelo propuesto.
20. Shanmugam et al. (2025), en Addressing Class Imbalance in Intrusion Detection: A Comprehensive Evaluation of Machine Learning Approaches, condujeron un estudio de diseño explicativo enfocado en evaluar rigurosamente el impacto de las estrategias de preprocesamiento. Emplearon métodos de rebalanceo algorítmico, como SMOTE y ADASYN, contrastados estadísticamente frente a diversos clasificadores estándar. Los resultados determinaron que el remuestreo incrementa drásticamente la tasa de detección de anomalías infrecuentes sin degradar el rendimiento métrico en clases mayoritarias. Este antecedente resulta teóricamente vinculante con el presente proyecto al validar la necesidad ineludible del preprocesamiento para ataques minoritarios.
21. Wu et al. (2025), en MARNet: An Efficient Two-Stage Intrusion Detection Model Based on Deep Learning, diseñaron un estudio experimental para optimizar la identificación de vectores de ataque infrecuentes en redes informáticas. Emplearon los datasets UNSW-

NB15 y NSL-KDD implementando la función de pérdida EQL v2 sobre redes neuronales residuales para mitigar el efecto negativo del desbalance de clases. La arquitectura propuesta alcanzó una precisión multiclase del 90.55

22. Zwane et al. (2019), en Ensemble Learning Approach for Flow-based Intrusion Detection System, ejecutaron un estudio experimental destined to improve the analysis of network flows through compound predictive methods. In their methodological design, they evaluated probabilistic and non-probabilistic ensemble techniques based on decision trees to classify intrusions. The results established that ensemble methods systematically surpass simple algorithms in generalization capability over anomalous traffic. Although this study establishes the fundamental basis for the use of combined architectures, its analysis lacks specific mechanisms for treating low-frequency attacks, a methodological gap that will be resolved through the proposed hybrid approach.

2.1.2 Antecedentes nacionales

1. Raico Gallardo (2025), en Desarrollo de un modelo de clasificación para la detección de anomalías en redes IoT utilizando el dataset CICIoT2023, desarrolló un estudio aplicado de enfoque cuantitativo con el fin de identificar patrones maliciosos en entornos de Internet de las Cosas. En su diseño metodológico, procesó una muestra de 7,829,178 registros del dataset CICIoT2023, evaluando algoritmos como Regresión Logística, Árboles de Decisión y Random Forest mediante la herramienta Scikit-learn. Los resultados determinaron que el modelo Random Forest alcanzó la mayor efectividad con un 98.63
2. Villarroel Enriquez (2025), en su tesis titulada Análisis dinámico de malware mediante algoritmos de detección basados en machine learning, ejecutó una investigación experimental orientada a fortalecer la seguridad en dispositivos móviles a través del análisis de comportamientos dinámicos. La metodología empleada consistió en la comparación de los algoritmos XGBoost, LightGBM y Random Forest, utilizando la frecuencia de llamadas al sistema como métrica principal. Los hallazgos principales destacou que el algoritmo LightGBM superó a los demás con una precisión del 94.1
3. León et al. (2024), en el trabajo Sistema que alerta la presencia de anomalías en logs de equipos IoT para prevenir el acceso no autorizado, propusieron una solución tecnológica para la detección temprana de vulnerabilidades en infraestructuras conectadas. El método

consistió en el desarrollo de un sistema autónomo capaz de analizar grandes volúmenes de logs de auditoría mediante scripts de Python. Los resultados evidenciaron una efectividad variable (65

4. Oblitas Mantilla y Escobedo Cárdenas (2024), en Prediction of PM2.5 and PM10 concentrations using XGBoost and LightGBM algorithms: A Case Study in Lima, Peru, realizaron un estudio cuantitativo aplicado a la predicción de variables ambientales complejas. Metodológicamente, los autores compararon el desempeño de XGBoost y LightGBM procesando series temporales masivas obtenidas en el distrito de San Borja. Los resultados demostraron que LightGBM ofrece una velocidad de entrenamiento superior y una mayor precisión en el manejo de datos voluminosos. Aunque el dominio de aplicación es ambiental, este antecedente es fundamental porque proporciona el sustento técnico y la validez metodológica en el Perú para la selección de XGBoost y LightGBM como los pilares del modelo de ensamble propuesto en esta tesis.
5. Curioso Mercado y Gonza Callenova (2025), en Propuesta de modelo de detección de ransomware basado en Aprendizaje Automático, desarrollaron una investigación experimental con el objetivo de identificar ataques de secuestro de datos antes de su ejecución. La metodología se centró en el preprocesamiento de características de red y el entrenamiento de modelos de clasificación supervisada para distinguir tráfico legítimo de patrones de cifrado. Los hallazgos indicaron que la optimización de hiperparámetros permite reducir drásticamente los falsos negativos en amenazas críticas. Este estudio se conecta con la presente investigación al subrayar la importancia del Recall, pero deja pendiente la mejora en la detección de ataques minoritarios, aspecto que se resolverá con el enfoque híbrido planteado.
6. Concha Ramos (2024), en Detección de intrusos en la red basado en red neuronal convolucional y aprendizaje por transferencia, ejecutó un estudio de nivel maestría para analizar el rendimiento de arquitecturas de aprendizaje profundo frente a ataques emergentes. El diseño metodológico empleó el dataset UNSW-NB15 y aplicó técnicas de Transfer Learning sobre Redes Neuronales Convolucionales (CNN) para evitar el reentrenamiento constante. Los resultados arrojaron una precisión del 85.22

2.1.3 Antecedentes locales

1.

2.2 Bases Teóricas

2.2.1 Internet de las Cosas (IoT) y Ciberseguridad

El Internet de las Cosas (IoT) se define como una red de objetos físicos interconectados que recolectan e intercambian datos. En este entorno, la seguridad es crítica debido al desbalance de datos en el tráfico de red, donde los ataques maliciosos son significativamente menos frecuentes que el tráfico benigno, dificultando su detección asertiva por parte de los sistemas convencionales.

2.2.2 Algoritmos de Gradiente Incrementado (Boosting)

Los algoritmos de Boosting construyen modelos de forma secuencial, donde cada nuevo modelo intenta corregir de manera iterativa los errores cometidos por los modelos anteriores, optimizando una función de pérdida específica.

2.2.3 XGBoost (Extreme Gradient Boosting)

Es una implementación optimizada del algoritmo de gradiente incrementado que utiliza un término de regulación para controlar el sobreajuste y mejorar la eficiencia computacional. Su función objetivo a optimizar se define como:

$$\mathcal{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k) \quad (2.1)$$

Donde l representa la función de pérdida que mide la diferencia entre la predicción $\hat{y}_i$ y el valor real y_i , mientras que Ω es el término de regularización que penaliza la complejidad del modelo para evitar el overfitting.

2.2.4 LightGBM (Light Gradient Boosting Machine)

Este algoritmo se diferencia por su técnica de crecimiento de árboles por hojas (*leaf-wise*) en lugar de niveles (*level-wise*). Este enfoque permite reducir la pérdida de forma más agresiva, me-

jorando la velocidad de entrenamiento y disminuyendo el uso de memoria en el procesamiento de grandes volúmenes de datos.

2.2.5 Ensamble por Stacking (Apilamiento)

El *Stacking* es una técnica de aprendizaje de ensamble que combina las predicciones de múltiples modelos base (en este estudio, XGBoost y LightGBM) mediante un meta-clasificador superior. El meta-modelo aprende la configuración óptima para combinar las salidas de los modelos base, maximizando así la capacidad de generalización y la robustez del sistema final.

2.2.6 Técnicas de Tratamiento de Desbalance de Clases

2.2.7 Borderline-SMOTE

Es una variante avanzada del algoritmo SMOTE (*Synthetic Minority Over-sampling Technique*) que genera ejemplos sintéticos exclusivamente en la “frontera” de decisión entre la clase minoritaria y la mayoritaria. Esta técnica es fundamental cuando el riesgo de clasificación errónea es elevado debido a la proximidad de ejemplos de diferentes clases en el espacio de características.

2.2.8 Métricas de Evaluación de Clasificación

Para evaluar la eficacia del modelo en la detección de ataques minoritarios, se utilizan métricas derivadas de la matriz de confusión, permitiendo una interpretación objetiva del rendimiento:

- **Accuracy (Exactitud):** Proporción de predicciones correctas sobre el total de casos evaluados.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.2)$$

- **Recall (Sensibilidad):** Capacidad del modelo para identificar correctamente los casos positivos reales (ataques). Es la métrica crítica en esta investigación para reducir los falsos negativos.

$$Recall = \frac{TP}{TP + FN} \quad (2.3)$$

- **F1-Score:** Media armónica entre la Precisión y el Recall, proporcionando una medida equilibrada del rendimiento en presencia de clases desbalanceadas.

$$F1-Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2.4)$$

2.3 Definición de Términos Básicos

Ataque Minoritario: Actividad maliciosa cuya frecuencia de aparición dentro de un conjunto de datos es significativamente baja en comparación con el volumen del tráfico normal o benigno.

Dataset CICIoT2023: Conjunto de datos estandarizado y actualizado, diseñado por el Canadian Institute for Cybersecurity, que contiene perfiles de ataques reales y actualizados en ecosistemas de dispositivos IoT.

Hiperparámetros: Configuraciones externas al modelo que se definen previo al proceso de entrenamiento (como la tasa de aprendizaje o profundidad del árbol) para optimizar su rendimiento.

Recall: Indicador métrico que cuantifica la habilidad de un clasificador para recuperar y etiquetar correctamente todos los casos positivos existentes en la muestra.

Stacking: Arquitectura de aprendizaje jerárquico donde un meta-modelo se entrena utilizando las predicciones de diversos modelos base para reducir el error de sesgo y varianza.

SMOTE: Algoritmo de sobremuestreo que incrementa artificialmente la representatividad de la clase minoritaria mediante la síntesis de nuevos datos basados en los vecinos más cercanos.

Verdaderos Positivos (TP): Cantidad de instancias en las que el modelo predijo correctamente la existencia de un ataque o anomalía.

CAPÍTULO III

MATERIALES Y MÉTODOS

3.1 Materiales

Para la ejecución del presente proyecto de investigación, se utilizaron recursos tecnológicos de alto rendimiento que permitieron el procesamiento masivo de datos y el entrenamiento complejo de los algoritmos de aprendizaje por ensamble.

3.1.1 Equipos

El hardware empleado consistió en una estación de trabajo portátil de gama alta, cuya inversión ascendió a 11,000.00 soles. Este equipo garantizó la estabilidad, capacidad de memoria y la velocidad de cómputo en paralelo requerida para las iteraciones de los modelos XGBoost y LightGBM sobre millones de registros.

Tabla 3.1: Especificaciones técnicas del hardware utilizado en la experimentación

Componente	Descripción Detallada
Procesador	Intel Core i7 de arquitectura multinúcleo para cálculos de entropía.
Memoria RAM	32 GB DDR5, esencial para evitar desbordamientos (<i>Out-of-Memory</i>) durante la ingesta de los conjuntos de datos y la generación sintética.
Tarjeta de Video	NVIDIA GeForce RTX 5070 Ti, utilizada para la aceleración por GPU.
Memoria VRAM	12 GB, indispensable para el procesamiento de tensores mediante la plataforma CUDA.
Almacenamiento	1 TB SSD NVMe, para la lectura y escritura de alta velocidad de los archivos <code>.csv</code> .

3.1.2 Software

La implementación lógica y arquitectónica se desarrolló en un entorno estandarizado para la Ciencia de Datos, basado íntegramente en software de código abierto.

Tabla 3.2: Herramientas de software y librerías empleadas

Herramienta	Versión / Función Específica
Sistema Operativo	Windows 11 Pro con el Subsistema de Windows para Linux (WSL Ubuntu 22.04 LTS).
Lenguaje base	Python 3.11, seleccionado por su eficiencia en el manejo de estructuras de datos.
Librerías de ML	<i>Scikit-learn</i> (Meta-clasificador), <i>XGBoost</i> y <i>LightGBM</i> (Modelos base), <i>Imbalanced-learn</i> (Algoritmo Borderline-SMOTE).
Análisis de Datos	<i>Pandas</i> y <i>NumPy</i> para la vectorización y segmentación de los tensores.
Validación Estadíst.	<i>SciPy</i> para la ejecución de la Prueba de Wilcoxon y análisis de significancia.

3.2 Metodología

3.2.1 Tipo de investigación

La investigación fue de tipo **Aplicada**, puesto que se orientó a la solución práctica de una vulnerabilidad tecnológica crítica: la ineficacia de los sistemas tradicionales para detectar intrusiones de baja frecuencia en ecosistemas IoT. Asimismo, el estudio tuvo un enfoque **Cuantitativo**, debido a que el rendimiento del modelo se midió de forma numérica, objetiva y probabilística a través de indicadores exactos (Recall, F1-Score, Accuracy y latencia en milisegundos) extraídos de matrices de confusión.

3.2.2 Diseño de investigación

El diseño de la investigación fue **Experimental**, específicamente de nivel **Cuasi-experimental**. En un entorno de simulación de laboratorio controlado, se manipuló intencionalmente la Variable Independiente (la implementación de la arquitectura Stacking combinada con XGBoost, LightGBM y el preprocesamiento Borderline-SMOTE) para observar, registrar y cuantificar su

efecto directo sobre la Variable Dependiente (la eficacia predictiva en la detección de ataques minoritarios).

Para garantizar la validez metodológica, se contrastó el desempeño de un Grupo Experimental (el modelo híbrido propuesto) contra un Grupo de Control (conformado por los modelos individuales y sin rebalanceo en la frontera).

3.2.3 Población y muestra

Población: La población de estudio estuvo conformada por los flujos de tráfico de red del conjunto de datos moderno **CICIoT2023**, publicado originalmente por el Instituto Canadiense de Ciberseguridad (CIC). Este repositorio constituyó un reflejo realista de la comunicación de dispositivos IoT (cámaras web, televisores inteligentes, termostatos y dispositivos portátiles) expuestos tanto a tráfico benigno como a amenazas cibernéticas avanzadas. El dataset poblacional contuvo 34 tipos de ataques distintos, abarcando escenarios críticos como Denegación de Servicio (DoS), Denegación de Servicio Distribuida (DDoS), ataques de fuerza bruta, redes de bots (*botnets*) y ataques de reconocimiento.

Muestra: Debido a la magnitud del conjunto de datos original, la muestra analizada se obtuvo a través de un repositorio estructurado alojado en la plataforma *Kaggle*. Este conjunto de datos ya se encontraba preprocesado y segmentado estratificadamente, asegurando una distribución representativa de las 47 características extraídas de los flujos de red (como el tamaño del paquete, duración de la conexión, indicadores estadísticos y *flags* de red). La muestra final constó de 7,845,673 registros, los cuales se dividieron operativamente de la siguiente manera:

- **Conjunto de Entrenamiento (Train):** Un tensor compuesto por 5,491,971 filas y 47 columnas, utilizado para la fase de aprendizaje algorítmico y rebalanceo.
- **Conjunto de Validación (Validation):** Un tensor de 1,176,851 filas y 47 columnas, empleado para la calibración sistemática de los hiperparámetros del modelo sin sesgar el entrenamiento.
- **Conjunto de Prueba (Test):** Un tensor de 1,176,851 filas y 47 columnas, estrictamente aislado durante el proceso de diseño para evaluar la capacidad de generalización del modelo final ante datos nunca antes vistos.

3.2.4 Técnicas e instrumentos de recolección de datos

- **Técnica:** Se empleó la observación experimental indirecta y la simulación computacional. Esta técnica consistió en la ejecución controlada de los algoritmos de clasificación sobre los tensores de datos preestablecidos, registrando iterativamente el comportamiento predictivo del modelo.
- **Instrumentos:** Se utilizaron *scripts* estructurados en Python para la ingesta y transformación de datos. El instrumento de medición principal fue la **Matriz de Confusión**, la cual tabuló algorítmicamente las clasificaciones correctas e incorrectas (Verdaderos Positivos, Falsos Negativos, etc.). Adicionalmente, se emplearon herramientas lógicas de perfilado (*profilers*) para medir la latencia de inferencia y la ocupación de memoria.

3.2.5 Procedimiento de la investigación

El desarrollo técnico del modelo híbrido se ejecutó secuencialmente a través de las siguientes fases detalladas:

1. **Fase de Preprocesamiento:** Se ingirieron los tres conjuntos de datos (Train, Validation y Test). Se aplicaron rutinas de normalización escalar sobre las 47 características de red para homogenizar las magnitudes numéricas (como el tamaño de paquetes en bytes vs. la duración en milisegundos) y se realizó un análisis de entropía para evaluar la incertidumbre informativa de los atributos.
2. **Fase de Rebalanceo Sintético:** Con el objetivo de evitar el sesgo predictivo (*Data Leakage*), el algoritmo **Borderline-SMOTE** se aplicó única y exclusivamente sobre el conjunto de entrenamiento (5,491,971 registros). Esta técnica identificó las instancias de ataques minoritarios ubicadas críticamente cerca de la frontera de decisión con el tráfico mayoritario, generando vectores sintéticos interpolados para equilibrar matemáticamente las clases.
3. **Fase de Entrenamiento (Modelos Base):** Sobre el conjunto de entrenamiento balanceado, se inicializaron y entrenaron de manera independiente los algoritmos de gradiente incrementado (XGBoost y LightGBM). Sus respectivos hiperparámetros fueron refinados iterativamente evaluando su pérdida (*loss*) contra el conjunto de validación de 1,176,851 registros.

4. **Fase de Integración (Arquitectura Stacking):** Se construyó un meta-clasificador superior. Las predicciones (probabilidades de clase) generadas por los modelos base en la fase anterior se utilizaron como variables de entrada (*features* adicionales) para que el meta-modelo aprendiera de manera jerárquica a corregir los errores residuales de los algoritmos subyacentes.
5. **Fase de Evaluación:** El modelo híbrido completamente ensamblado se enfrentó al conjunto de prueba (Test) aislado de 1,176,851 registros. Las salidas generadas se introdujeron en la Matriz de Confusión para el cálculo definitivo de los indicadores de eficacia.

3.2.6 Análisis de datos

El análisis estadístico de los resultados se llevó a cabo para validar la robustez de la propuesta. En primer lugar, se extrajeron las métricas computacionales directas: *Recall* (priorizado por su relevancia en la detección de ataques ocultos o minoritarios), *F1-Score* y *Accuracy*.

Finalmente, debido a que el comportamiento de los modelos de *Machine Learning* en arquitecturas de ensamble no sigue estrictamente una distribución de probabilidad normal, se aplicó la **Prueba de Rangos con Signo de Wilcoxon** (*Wilcoxon Signed-Rank Test*). Esta prueba no paramétrica permitió comparar los vectores de predicción del modelo Stacking propuesto contra los modelos base individuales (Grupo de Control), evaluando bajo un nivel de significancia $\alpha = 0,05$ (95 % de confianza) si la mejora en la detección de los ataques minoritarios resultó ser estadísticamente significativa, lo que condujo a la aceptación de la hipótesis general de la investigación.

CAPÍTULO IV

RESULTADOS Y DISCUSIÓN

4.1 Resultados

Resultados del estudio.

4.2 Discusión

Discusión de resultados.

CAPÍTULO V

CONCLUSIONES

5.1 Conclusión 1

Texto de conclusión 1.

5.2 Conclusión 2

Texto de conclusión 2.

5.3 Conclusión 3

Texto de conclusión 3.

CAPÍTULO VI

RECOMENDACIONES

6.1 Recomendación 1

Texto de recomendación 1.

6.2 Recomendación 2

Texto de recomendación 2.

CAPÍTULO VII

ANEXOS

7.1 Anexo A: Título del anexo A

Contenido del anexo A.

7.2 Anexo B: Título del anexo B

Contenido del anexo B.