

Sistema Híbrido de Recomendación de Laptops

Arquitectura en Cascada de 2 Niveles para E-Commerce de Hardware

Roger Vilcacari

Sistemas de Recomendación - Proyecto Final

3 de agosto de 2026

Introducción y Motivación

- **Contexto:** La elección de una laptop es un proceso complejo. Involucra alta inversión económica y la necesidad de emparejar requisitos técnicos estrictos con perfiles de uso muy variados (estudiantes, programadores, arquitectos, gamers).
- **Problema Central:** Los sistemas de recomendación actuales en plataformas de E-Commerce suelen basarse únicamente en popularidad o historial de compras, ignorando la incompatibilidad técnica (Ej. recomendar una laptop Celeron a un diseñador 3D solo porque es "muy vendida").
- **Objetivo:** Desarrollar un sistema experto híbrido que garantice el 100 % de cumplimiento de restricciones técnicas y que además ofrezca una experiencia personalizada mitigando la falta de historial.

Definición de los Retos Técnicos

Reto 1: El *Cold Start* (Inicio en frío)

Las personas renuevan sus laptops cada 3-5 años. En la mayoría de sesiones, el usuario es "nuevo" para el sistema. El **Filtrado Colaborativo** puro colapsa sin datos de interacción previos.

Reto 2: Restricciones Duras (Constraints)

En dominios de entretenimiento (cine, música), un falso positivo genera disgusto temporal. En hardware, un falso positivo (ej. recomendar una laptop sin GPU para tareas pesadas) invalida toda la compra.


Reto 3: Espacio Multidimensional

La relevancia no se define por "marca", sino por un vector compuesto por RAM, Almacenamiento, Tasa de Refresco, GPU, CPU, etc.

Para el entorno de validación, se procesó información de escenarios reales:

- **Fuente de Datos:** Dataset "Laptop Price Prediction" de Kaggle (2024).
- **Volumen:** 1,273 modelos únicos de laptops reales en el mercado.
- **Preprocesamiento y Extracción:**
 - ▶ Conversión automatizada de monedas a USD.
 - ▶ Extracción mediante *Regex* de componentes vitales: Cantidad de RAM (GB), núcleos de CPU, existencia de GPU Dedicada y soporte CUDA.
 - ▶ Creación de un "Screen Score" basado en resoluciones y tecnologías de panel.
- **Simulación Colaborativa:** Generación de casi 3,000 interacciones (ratings) sintéticas divididas en arquetipos (Gamers, Estudiantes, Editores) para entrenar el modelo latente.

Solución: Arquitectura Híbrida en Cascada



Nivel 1: Inferencia Lógica (Filtro Duro)

Actúa como la barrera principal del sistema. Transforma las especificaciones del usuario en **reglas binarias (Constraints)**.

Construcción Matemática de la Máscara

Para cada laptop i , se genera un escalar M_{rules} :

$$M_{rules}(i) = \begin{cases} 1 & \text{si } P_i \leq B \wedge (R_i \geq R_{min}) \wedge (V_i \geq V_{min}) \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (1)$$

- **Ejemplo:** Si el perfil es *Data Science*, se fuerza $RAM \geq 16GB$ y GPU con CUDA.
- Cualquier equipo con $M_{rules}(i) = 0$ queda descartado permanentemente, reduciendo el espacio de búsqueda y eliminando la fricción de falsos positivos.

Nivel 2 (Sub-Modelo A): Teoría de Utilidad (MAUT)

El *Multi-Attribute Utility Theory* (Knowledge-Based) permite puntuar laptops incluso si **ningún usuario las ha comprado antes**.

El usuario define la importancia (pesos w) que le da a distintas dimensiones. El modelo normaliza (Min-Max) los valores técnicos de la laptop (S).

Cálculo de Utilidad U_{maut}

$$U_{maut}(i) = w_{precio} \cdot S_p(i) + w_{rendimiento} \cdot S_r(i) + w_{pantalla} \cdot S_s(i) + w_{portab.} \cdot S_m(i) \quad (2)$$

- Las métricas se normalizan al rango $[0, 1]$.
- Ej: Para S_{precio} , los equipos más económicos obtienen mayor puntaje cercano a 1.

Nivel 2 (Sub-Modelo B): Factorización SVD

Modelo **Collaborative Filtering** diseñado para descubrir patrones de consumo de la comunidad que no son obvios matemáticamente (ej. lealtad de marca).

Predicción de Calificación $\hat{r}$

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T p_u \quad (3)$$

- μ : Promedio global.
- b_u, b_i : Sesgos del usuario (criticismo) y del ítem (popularidad global).
- $q_i^T p_u$: Producto punto de los vectores latentes (Factores Ocultos).
- Se entrena minimizando el error con **Stochastic Gradient Descent (SGD)**.
- *Normalización*: El resultado (de 1 a 5 estrellas) se escala a $[0, 1]$ para sumarse al híbrido.

Nivel 2 (Sub-Modelo C): Similitud Coseno

Modelo **Content-Based** que mide la proximidad geométrica entre lo que el usuario necesita y lo que la laptop ofrece.

Métrica de Distancia Vectorial

Se genera un vector ideal del usuario v_u y un vector de la laptop v_i .

$$S_{content}(i) = \cos(v_u, v_i) = \frac{v_u \cdot v_i}{\|v_u\| \|v_i\|} \quad (4)$$

- El vector incluye: [RAM_Score, CPU_Score, GPU_Score, Calidad_Pantalla].
- Ignora el precio, centrándose exclusivamente en el paralelismo de las capacidades técnicas.

Ecuación Híbrida y Estrategia de Pesos Dinámicos

Los tres modelos se integran en una combinación lineal ponderada, condicionada por el Nivel 1.

Función de Puntaje Global

$$Score_i = M_{rules}(i) \times \left[\alpha \cdot U_{maut}(i) + \beta \cdot \hat{r}_{svd_norm}(i) + \gamma \cdot S_{content}(i) \right] \quad (5)$$

Mitigación Inteligente del Cold Start: Los coeficientes cambian según la madurez del usuario.

- **Usuario Nuevo (Cold Start):** $\alpha = 0,60$ (Fuerte peso a reglas y preferencias), $\gamma = 0,30$, $\beta = 0,10$ (Se apaga casi por completo la predicción comunitaria).
- **Usuario Frecuente:** $\alpha = 0,30$, $\beta = 0,50$ (Se le da poder a la sabiduría colaborativa).

Implementación del Sistema Web (Dashboard)

Para validar su funcionamiento, se construyó una interfaz E-Commerce funcional:

- **Backend:** Servidor en Python usando FastAPI de alto rendimiento.
- **Almacenamiento:** Modelos pre-entrenados cargados en memoria y base de datos vectorizada.
- **Frontend:** SPA interactiva (HTML5, JS, CSS Glassmorphism) que permite ajustar los factores de peso y probar distintos perfiles en tiempo real.
- **Endpoints:** `/api/recommend` recibe el JSON de preferencias y ejecuta la cascada en fracciones de segundo.

Evaluación Científica: Constraint Satisfaction Rate (CSR)

Se evaluó qué porcentaje de los Top-10 recomendados eran realmente **útiles** para el usuario (cumplían sus mínimos técnicos):

Algoritmo	CSR@10
SVD Puro	31.7 %
Content-Based Puro	48.3 %
Arquitectura Híbrida	93.3 %

Análisis

El SVD tradicional recomienda ítems populares que a menudo violan el presupuesto o el uso específico. El Sistema Híbrido, gracias a M_{rules} , es virtualmente impecable.

Predictividad Colaborativa (RMSE):

- RMSE del modelo SVD en dataset de test: **1.033**
- Demuestra que el algoritmo SVD logra predecir el interés a 1 estrella de margen.

Precisión@10 y Recall@10:

- En escenarios de *Cold Start*, las métricas clásicas son engañosamente bajas, pero la integración del vector de conocimiento MAUT asegura que las recomendaciones sean objetivamente relevantes para el perfil consultado.

Conclusiones y Trabajo Futuro

- **Hibridación en Cascada:** Un modelo puramente basado en IA generativa o colaborativa no es seguro para comercio de hardware. Los sistemas basados en restricciones (*Constraint-based*) son imperativos.
- **Solución MAUT:** Transformar specs técnicas crudas a una "función de utilidad" normalizada resolvió la asimetría de los datos y permitió recomendaciones perfectas sin interacciones pasadas.
- **Trabajo Futuro:**
 - ▶ Integrar procesamiento de lenguaje natural (NLP) para que el usuario escriba sus necesidades en texto libre.
 - ▶ Migración a Bases de Datos Vectoriales (*Milvus* o *Pinecone*) para escalar a catálogos de millones de productos.

¡Muchas Gracias!

Arquitectura Híbrida de 2 Niveles para E-Commerce

Turno de Preguntas y Respuestas